Licenciatura em Ciência de Dados

Unidade Curricular de Armazenamento Para Big Data

2º ano, 1º semestre

Ano Letivo 2025/2026

Docente: António Luís Lopes

TRABALHO FINAL – ATP PLAYERS

UNIDADE CURRICULAR DE ARMAZENAMENTO PARA BIG DATA

GRUPO 04

Fábio Alexandre Alves Gonçalves | 130 662

Martim Duarte Sousa | 130 629

Miguel Matos Galvão | 106 560

Simão Rafael dos Anjos Reis | 130 618

ÍNDICE

1. INTRODUÇÃO/OBJETIVO 2

3. CARACTERIZAÇÃO DA BASE DE DADOS 3

5. CRIAÇÃO DE COLEÇÕES E LIMPEZA 5

i. LIMPEZA E TRATAMENTO DE DADOS (MONGO) 5

6. COLEÇÃO "PLAYERS" 5

i. TRATAMENTO DOS ATRIBUTOS *"HAND"* E *"BORN"* 6

ii. FUZZY MATCHING ALGORITHM – APPROXIMATE STRING MATCHING 7

7. COLEÇÃO "TOURNAMENTS" 8

i. TRATAMENTO DO CAMPO "*DATE*" 9

ii. TRATAMENTO DO CAMPO "GROUND" E "PRIZE" 11

iii. VIEW "GRAND_SLAMS" 12

8. COLEÇÃO "PLAYER_PER_GAME" 12

i. TRATAMENTO DOS ATRIBUTO "OPONENT", "GROUND" E "PLAYERNAME" 13

ii. NORMALIZAÇÃO DO ATRIBUTO "*SCORE*" 15

iii. NORMALIZAÇÃO DOS PAÍSES NA COLEÇÃO "COUNTRYCODES" 15

iv. TRATAMENTO DO ATRIBUTO "GAMERANK" 16

9. IMPORTAÇÃO DOS FICHEIROS E CRIAÇÃO DAS TABELAS EM MYSQL 17

10. CRIAÇÃO DO MODELO RELACIONAL 18

11. CRIAÇÃO DE CHAVES PRIMÁRIAS E ESTRANGEIRAS 19

12. CONCLUSÃO 20

13. WEBGRAFIA 21

1. INTRODUÇÃO/OBJETIVO

O presente trabalho tem como objetivo principal analisar e tratar uma base de dados relativa a jogos de ténis profissional masculino, incluindo a limpeza, a transformação dos dados e a criação de um modelo relacional capaz de suportar consultas.

A *Association of Tennis Professionals* (*ATP Tour*) constitui o principal circuito mundial de ténis profissional masculino. A sua plataforma online fornece dados detalhados sobre jogadores, torneios, resultados, rankings e estatísticas (tipo de piso, prémios monetários, entre outros).

Entre as principais iniciativas da ATP, destaca-se a implementação, a 23 de agosto de 1973, do sistema oficial de classificação. Este mecanismo permite avaliar computacionalmente o desempenho dos jogadores, monitorizar a evolução do ranking ao longo do tempo e determinar as qualificações para os torneios.

Para a execução deste trabalho, foram utilizadas duas ferramentas complementares. Numa primeira fase, o *MongoDB* serviu para o armazenamento e pré-processamento dos dados. Posteriormente, as coleções tratadas foram importadas para o *PhpMyAdmin através do Python*, onde foram convertidas em tabelas estruturadas que serviram de base para a execução das consultas em *MySQL*.

2. DATASETS DE APOIO AO TRATAMENTO DE DADOS

Para o tratamento de dados dos atributos "*Born*" da coleção "*Players*" e "*Location*" da coleção "*Tournaments*" foram utilizados vários *datasets* complementares intitulados:

- "***data.csv***", onde constam dois atributos denominados "*Name*" e "*Code*". Esta foi associada à coleção "*CountryCodes*", contabilizando 249 registos no total;
- "***world-cities.csv***", onde constam três atributos denominados "*City*" e "*Country*" e "*SubCountry*". Posteriormente foi realizada a importação do atributo "*Code*" para esta coleção, a qual foi renomeada para "*World_Cities*", garantido que os 32 748 registos tivessem um "*Code*" associado.
- "***player_db.csv***", esta conta com cinco atributos sendo eles o *"player_id","name_first","name_last","full_name"* e *"iso2",* contando com 64 343 registos.

Através dessa informação foi possível corrigir algumas incoerências e/ou *missing values*.

3. CARACTERIZAÇÃO DA BASE DE DADOS

Os dados analisados foram obtidos a partir da plataforma oficial da *ATP Tour* (https://www.atptour.com/en), abrangendo todos os jogos individuais de 9 960 jogadores masculinos, focando-se nos 500 melhores jogadores do mundo entre 28/03/1973 e 14/02/2022. A base de dados intitulada "ATP" tem 16 atributos, estando estes caracterizados na Tabela 1. Caracterização descritiva dos atributos da base de dados.

Tabela 1. Caracterização descritiva dos atributos da base de dados

ATRIBUTOS	CARACTERIZAÇÃO
_id	Identificador, atribuído pelo *MongoDB*, para cada registo individual[1]
PlayerName	Nome do Jogador
Born	Local de nascimento, no formato *(City, Country)*
Height	Altura, em cm, do jogador [2]
Hand	Mão utilizada, no formato *(FrontHand, BackHand)* [3]
LinkPlayer	Link Identificador Único do jogador na plataforma ATP
Tournament	Nome do Torneio
Location	Local de realização do torneio, no formato *(City, Country)*
Date	Data de realização do torneio, no formato *(StartDate - EndDate)*
Ground	Tipo de piso em que o jogo foi disputado
Prize	Valor monetário do prémio atribuído ao vencedor de cada torneio
GameRound	Etapa do torneio em que o jogo foi disputado
GameRank	Ranking do jogo disputado, no Torneio
Oponent	Nome do Jogador Adversário
WL	Resultado do jogo, se o jogador venceu (W); se perdeu (L)
Score	Resultado do jogo, apresentado por sets, no formato (J1J2 J3J4), em que cada par de dígitos representa os jogos ganhos pelo vencedor e pelo adversário em cada set, respetivamente

[1] A variável *"_id"* é o único atributo que está no formato *ObjectID*.
[2] As variáveis "*Height*" e "*GameRank*" são valores inteiros, no formato *Int32*.
[3] Todas as restantes variáveis estão no formato *String*.

4. IMPORTAÇÃO DA BASE DE DADOS PARA O MONGODB

O primeiro passo consistiu na importação do ficheiro disponibilizado no Moodle, *atpplayers.json*, para o *MongoDB*, utilizando o seguinte comando:

mongoimport --db ATP --collection matches --file c:\data\atpplayers.json

Para garantir que a importação fosse realizada corretamente, sem erros ou alterações indesejadas na estrutura dos dados, procedeu-se à verificação de alguns registos da base de dados, através do seguinte comando.

mongosh use ATP db.matches.find().pretty()

O presente código na *mongosh* gerou o *output* que seria expectável, com todos os atributos por registo, tal como é possível visualizar na Figura 1. Integridade dos registos em MongoDB, após a importação.

```
>_MONGOSH
> db.matches.find().pretty()
< {
    _id: ObjectId('624ab34913b144c54b3c9aba'),
    PlayerName: 'Novak Djokovic',
    Born: 'Belgrade, Serbia',
    Height: 188,
    Hand: 'Right-Handed, Two-Handed Backhand',
    LinkPlayer: 'https://www.atptour.com/en/players/novak-djokovic/d643/player-activity?year=all&matchType=Singles',
    Tournament: 'Davis Cup Finals',
    Location: 'Madrid, Spain',
    Date: '2021.11.22 - 2021.12.05',
    Ground: 'Hard',
    Prize: '',
    GameRound: 'Semi-Finals',
    GameRank: 30,
    Oponent: 'Marin Cilic',
    WL: 'W',
    Score: '64 62'
  }
```

Figura 1. Integridade dos registos em MongoDB, após a importação

5. CRIAÇÃO DE COLEÇÕES E LIMPEZA

No *MongoDB* foi criada uma *database* intitulada "*ATP_Players*". Posteriormente, procedeu-se à criação de diversas coleções destinadas à análise exploratória dos dados. As coleções criadas foram as seguintes:

- Coleção "*Players*"
- Coleção "Tournaments"
- Coleção "Player_Per_Game"

i. LIMPEZA E TRATAMENTO DE DADOS (MONGO)

Após a criação e análise prelimiar das coleções, optou-se por realizar o tratamento de dados exclusivamente no *MongoDB*, uma vez que foram identificadas várias incoerências.

Em seguida, efetuou-se uma análise individual de cada coleção e respetivos atributos, de forma a identificar inconsistências, *missing values* e erros estruturais, aplicando as correções necessárias antes da migração para o *MySQL*.

6. COLEÇÃO "PLAYERS"

Foi criada a coleção "*Players*", de modo a caracterizar cada jogador individualmente. Para realizar essa análise, inicialmente, foram utilizados os seguintes atributos presentes na Tabela 2. Caracterização descritiva dos atributos da coleção "Players".

Tabela 2. Caracterização descritiva dos atributos da coleção "Players"

ATRIBUTOS	CARACTERIZAÇÃO
_id	Identificador, atribuído pelo *MongoDB*, para cada registo individual
PlayerName	Nome do Jogador
Born	Local de nascimento, no formato *(City, Country)*
Height	Altura, em cm, do jogador
Hand	Mão utilizada, no formato *(FrontHand, BackHand)*
LinkPlayer	Link Identificador Único, do jogador, na plataforma ATP

Como o "*LinkPlayer"* é o Identificador Único do jogador na plataforma ATP, decidiu-se agrupar as diversas características de cada registo por esse mesmo atributo. Recorreu-

se ao operador "*$group*" para essa agregação e o "*LinkPlayer*" foi definido como chave ("*_id*") desse agrupamento.

Para garantir que a coleção "*Players*" apresentasse apenas uma entrada por jogador, recorreu-se ao operador "*$first*" no contexto do "*$group*", selecionando o primeiro valor encontrado para cada atributo dentro de cada agrupamento de registos.

O resultado desta pipeline de agregação foi posteriormente armazenado na coleção "*Players*" através do operador "*$merge*".

i. TRATAMENTO DOS ATRIBUTOS *"HAND"* E *"BORN"*

Em seguida, procedeu-se à decomposição do atributo "*Hand*", originalmente armazenado como um único campo. Dividindo-o, em "*FrontHand*" e "*BackHand*", permitindo distinguir a mão dominante utilizada pelos jogadores, *forehand* (designação técnica correta) e da "*backhand*". Uma divisão semelhante foi aplicada ao campo "*Born*", que inicialmente agregava informação sobre a cidade e o país de nascimento. Assim, foram criados dois campos distintos "*BornCity*" e "*BornCountry*" facilitando a análise geográfica da origem dos atletas.

No âmbito da limpeza de dados, foram ainda corrigidos todos os valores nulos presentes no campo *"FrontHand",* (3987 registos) substituindo-os pelo valor "*Unknown*", de forma a evitar incoerencias em consultas posteriores. Adicionalmente, corrigiram-se problemas de codificação nos nomes dos jogadores, como no caso de "*Julián Gimenez*", "*François Musitelli*", em que o caractere especial, (" 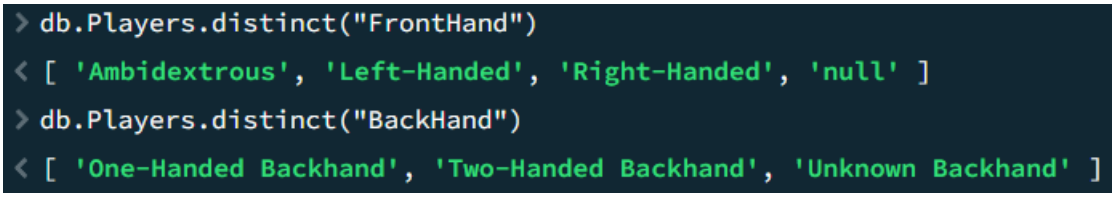 ") não estava a ser interpretado corretamente, devido ao encoding utilizado.

```
> db.Players.distinct("FrontHand")
< [ 'Ambidextrous', 'Left-Handed', 'Right-Handed', 'null' ]
> db.Players.distinct("BackHand")
< [ 'One-Handed Backhand', 'Two-Handed Backhand', 'Unknown Backhand' ]
```

Figura 2. Valores presentes nas colunas "FrontHand" e "BackHand"

Os *missing values* na coluna *"FrontHand"* estavam com o valor "*null*" e foram atualizados para *"Unknown"*

```
> db.Players.distinct("FrontHand")
< [ 'Ambidextrous', 'Left-Handed', 'Right-Handed', 'Unknown' ]
```

Figura 3. Valores presentes na coluna "FrontHand" depois da limpeza

Um dos aspetos que também exigiu intervenção manual foi relativo ao campo *"Height"*. Identificaram-se valores incorretos, alturas listadas como "*{Height: 15}*", "*{Height: 71}*" e "*{Height: 510}*" que tiveram de ser corrigidas manualmente para os valores reais. Alturas classificadas como "NA" (6317 registos), foram substituídas por 0 para manter coerência no tipo de dados (int32). Há dois jogadores, "*Mateo Andres Ruiz Naranjo*" e "*Jorge Pantas*" que têm "*{Height: 3}*", mas não existe nenhuma fonte credível disponível sobre as mesmas, então optou-se também por substituir pelo valor "*{Height: 0}*". [4]

ii. FUZZY MATCHING ALGORITHM – APPROXIMATE STRING MATCHING

Após a consolidação da coleção "*Players*", considerou-se pertinente realizar um processo de correspondência (*Função de distância de Levenshtein*) com uma base de dados externa contendo milhares de nomes de jogadores profissionais de ténis, com o objetivo de validar a informação presente na coleção e identificar eventuais discrepâncias ou nomes não normalizados. Para essa tarefa, foi testado o *Fuzzy Matching Algorithm*.

Este algoritmo consiste numa abordagem flexível baseada em técnicas capazes de identificar similaridades mesmo quando existem pequenas variações, erros ortográficos ou diferenças na formatação dos nomes, algo que acontece na nossa base de dados.

O processo de *fuzzy matching* foi então executado para 237 jogadores que não tinham obtido correspondências diretas anteriormente. Apesar de computacionalmente intensivo, o algoritmo conseguiu identificar 130 correspondências prováveis, ordenadas por níveis de confiança. Os resultados evidenciaram casos em que diferenças mínimas, como acentuação, espaços ou variações de apelidos, impediam o *match* exato, mas eram corretamente captados por esta abordagem, tal como demonstra a Figura 4. Fuzzy Matching Algorithm.

[4] É importante reforçar que todos os jogadores descritos nas situações previamente mencionadas, têm essas informações disponíveis publicamente nos diversos sites mencionados na Webgrafia.

```
=== RELATÓRIO FINAL ===
Total de jogadores processados: 9960
Jogadores com match: 0
Jogadores sem match: 237

=== Iniciando FUZZY MATCHING para casos não resolvidos ===

=== FUZZY MATCHING COMPLETO ===
Matches encontrados com fuzzy: 130

Primeiros 50 matches (ordenados por confiança):
Daniel Ramentol-Garcia Atienza → Daniel Ramentol Garcia Atienza (96.7%) [ESP]
Mohammed Abdel-Aziz Al Nuaimi → Mohammed Abdel Aziz Al Nuaimi (96.6%) [UAE]
Jose Antonio Sanchez-de Luna → Jose Antonio Sanchez De Luna (96.4%) [ESP]
Christian Florentin Voinea → Cristian Florentin Voinea (96.2%) [ROU]
Corrado Degl'Incerti Tocci → Corrado Deglincerti Tocci (96.2%) [ITA]
```

Figura 4. Fuzzy Matching Algorithm

No entanto, verificou-se que a execução integral deste procedimento para toda a base de dados exigia um tempo computacional demasiado elevado, e apesar de resultados bons ainda iriam atletas sem correspondencia, tornando o processo impraticável no contexto do projeto. Por esse motivo decidiu-se não integrar o *fuzzy matching* nas etapas de preparação da coleção *"Players"*, registando-se apenas os resultados do ensaio exploratório realizado.

7. COLEÇÃO "TOURNAMENTS"

Foi criada a coleção "*Tournaments*", para caracterizar cada torneio de maneira individual. A realização da análise descritiva baseou-se nos seguintes atributos presentes na Tabela 3. Caracterização descritiva dos atributos da coleção "Tournaments".

Tabela 3. Caracterização descritiva dos atributos da coleção "Tournaments"

ATRIBUTOS	CARACTERIZAÇÃO
Tournament	Nome do Torneio
Location	Local de realização do torneio, no formato *(City, Country)*
Date	Data de realização do torneio, no formato *(StartDate - EndDate)*
Ground	Tipo de piso do jogo em que o jogo foi disputado
Prize	Valor monetário do prémio atribuído ao vencedor de cada torneio

Para garantir a unicidade de cada torneio e eliminar registos duplicados, recorreu-se ao operador *$group* definindo como chave composta os campos "*Tournament*" e "*Date*". Esta agregação assegura que cada combinação única de torneio e data resulta num único documento.

Através do operador de acumulação *$first*, reteve-se apenas a primeira ocorrência de cada combinação única torneio-data, eliminando assim os duplicados. O resultado desta pipeline de agregação foi posteriormente armazenado na coleção "*Tournaments*" através do operador *$merge*.

```
>_MONGOSH
> db.Tournaments.find().pretty()
< {
    _id: ObjectId('6931b52ed2e6042393484663'),
    Date: '1914.08.24 - 1914.09.01',
    Ground: 'Grass',
    Location: 'Newport, Rhode Island, United States',
    Prize: '',
    Tournament: 'US Championships'
  }
```

Figura 5. Integridade de um registo da tabela "Tournaments"

Numa primeira fase de limpeza, foi criado um índice sobre o campo "*Tournament*" e sobre o campo "*Date*" com o objetivo de otimizar consultas e evitar futuras inserções incongruentes, dado que dois torneios distintos não podem ocorrer com a mesma designação e na mesma data.

i. TRATAMENTO DO CAMPO "*DATE*"

Procedeu-se também à remoção de todas as datas que se encontravam fora do intervalo temporal válido. Identificaram-se ainda 662 torneios cujo campo "*Date*" incluía apenas a data de início. Estes documentos foram mantidos, mas devidamente assinalados para tratamento posterior, garantindo transparência sobre a ausência de informação relativa à data de término.

Com o intuito de aumentar o rigor e a precisão da informação, o campo "*Location*", originalmente armazenado no formato "*City*, *Country*", foi dividido em dois atributos distintos: "*TournamentCity*" e "*TournamentCountry*". De igual modo, o campo "*Date*" foi desagregado nos atributos "*StartDate*" e "*EndDate*", permitindo representar a duração

exata de cada torneio. Posteriormente foram encontrados dois registos com intervalos temporais errados. Através do seguinte comando:

```
> db.Tournaments.find({
    StartDate: { $gt: "" },
    EndDate: { $gt: "" },
    $expr: { $gt: ["$StartDate", "$EndDate"] }
  })
```

Figura 6. Comando para encontrar casos de datas inválidas

O registo presente na Figura 7. Torneio ECU vs. CAN - AMERICA SF tem os atributos *"StartDate"* e *"EndDate"* errados. Através de alguma pesquisa, foi possível confirmar que este torneio fez parte da *1983 David Cup America Zone.* O torneio teve lugar entre os dias 6 e 8 de maio de 1983. Foi realizado um comando *updateOne* a este registo.

```
< {
    _id: ObjectId('6931b52ed2e6042393484c42'),
    Ground: 'Clay',
    Location: 'Guayaquil, Ecuador',
    Prize: 'Unknown',
    Tournament: 'ECU vs. CAN - AMERICA SF',
    StartDate: '1983.05.02',
    EndDate: '1973.05.08'
  }
```

Figura 7. Torneio ECU vs. CAN - AMERICA SF

O registo presente na Figura 8. Torneio New Haven apresenta os campos *"StartDate"* e *"EndDate"* trocados, pelo que foi realizado um comando *updateOne* a este registo. [5]

```
  {
    _id: ObjectId('6931b52ed2e60423934852bb'),
    Ground: 'Hard',
    Location: 'New Haven, CT, U.S.A.',
    Prize: '$50,000',
    Tournament: 'New Haven',
    StartDate: '1992.08.10',
    EndDate: '1992.08.09'
  }
```

Figura 8. Torneio New Haven

[5] É importante reforçar que todos os torneios descritos nas situações previamente mencionadas, têm essas informações disponíveis publicamente nos diversos sites mencionados na Webgrafia.

Foram mantidos os 662 *missing values* no atributo *"EndDate" {EndDate:null}* visto que não irá interferir com as análises que serão realizadas em *MySQL*. Esses *missing values* representam 3% da base de dados total, pelo que decidiu-se manter igual.

ii. TRATAMENTO DO CAMPO "GROUND" E "PRIZE"

Em seguida, efetuou-se uma revisão detalhada do campo "*Ground"*. Após uma análise percebeu-se a grande maioria dos *missing values* eram de três torneios (*M15 Antalya, M15 Cancun, M15 Opava*). Realizou-se uma breve pesquisa por esses três torneios e substituiu-se pelo seu tipo de piso correto.[6]

Nos três casos em que não foi possível identificar o piso correspondente, o campo foi preenchido com a categoria "*Unknown*", mantendo uniformidade no tratamento das ausências de informação. O mesmo tipo de intervenção foi realizado no campo "*Prize"*, onde se verificou a existência de caracteres especiais indevidos ("**[?]**"), os quais foram substituidos pelo caracter "$" para uniformizar todos os prizes. Os missing values e os valores nulos ("", *null* e *NA*) encontrados, representam 2 495 ocorrências, as quais foram corrigidas através da alteração do valor inicial pelo valor "*Unknown*".

Para suportar operações posteriores de validação geográfica, foram criados índices adicionais sobre os campos "*TournamentCity"*, "*TournamentCountry"* e "*Code"*. Estes índices foram fundamentais para a harmonização dos códigos de país associados aos torneios. Nos casos em que "*Code*" se encontrava vazio ou não existia, procedeu-se a uma correspondência direta com a base de dados de países *"CountryCodes"* quando era encontrada equivalência, o "*Code*" correto era automaticamente atribuído.

Em situações excecionais, nomeadamente quando o valor presente em "*TournamentCity"* correspondia ao nome de um país e não de uma cidade, foram realizadas correções manuais.

[6] É importante reforçar que todos os torneios descritos nas situações previamente mencionadas, têm essas informações disponíveis publicamente nos diversos sites mencionados na Webgrafia.

```
>_MONGOSH
> db.Tournaments.find().pretty()
< {
    _id: ObjectId('693b1d23c25b262634a062a5'),
    Tournament: 'Korea F3',
    Date: '2008.05.12 - 2008.05.18',
    Ground: 'Hard',
    Location: 'Korea',
    Prize: '$15,000'
  }
```

Figura 9. Integridade de um registo da tabela "Player_Per_Name"

iii. VIEW "GRAND_SLAMS"

Após a criação da coleção "*Tournaments*" foi criada uma *view* auxiliar com todos os registos de *Grand Slams*, ou seja, todos os torneios com os nomes *"Roland Garros", "Wimbledon", "US Open", "Australian Open"*.

Durante a inspeção da base de dados, identificámos que para o torneio "*Australian Open"* existiam duas entradas distintas no mesmo ano. Após alguma investigação, verificou-se que este fenómeno realmente aconteceu em 1977, o "*Australian Open"* foi realizado duas vezes no mesmo ano devido a uma alteração no calendário do torneio. Como ambos os vencedores do torneio têm os seus prémios reconhecidos decidiu-se manter os dados de ambos os torneios.

8. COLEÇÃO "PLAYER_PER_GAME"

Foi criada a coleção "*Player_Per_Game*", para caracterizar cada jogo realizado. A análise descritiva foi conduzida inicialmente com base nos seguintes atributos descritos na Tabela 4. Caracterização descritiva dos atributos da coleção "*Player_Per_Game*".

Tabela 4. Caracterização descritiva dos atributos da coleção "Player_Per_Game"

ATRIBUTOS	CARACTERIZAÇÃO
PlayerName	Nome do Jogador
Tournament	Nome do Torneio
Date	Data de realização do torneio, no formato *(StartDate - EndDate)*
Ground	Tipo de piso do jogo em que o jogo foi disputado
Prize	Valor monetário do prémio atribuído ao vencedor de cada torneio
GameRound	Etapa do torneio em que o jogo foi disputado
GameRank	Ranking do jogo disputado, no Torneio

Oponent	Nome do Jogador Adversário
WL	Resultado do jogo, se o jogador venceu (W); se perdeu (L)
Score	Resultado do jogo, apresentado por sets, no formato (J1J2 J3J4), em que cada par de dígitos representa os jogos ganhos pelo vencedor e pelo adversário em cada set, respetivamente

A coleção "*Player_Per_Game*" foi criada em duas etapas. Primeiro, utilizou-se o operador "*$project*" na coleção *matches* para selecionar e renomear os campos relevantes de cada participação.

Através do operador "*$first*", reteve-se apenas a primeira ocorrência de cada combinação única. Os documentos resultantes foram então agregados na coleção "*Player_Per_Game*" através do operador "*$merge*" com a estratégia de substituição para duplicados.

```
>_MONGOSH
> db.Player_Per_Game.find().pretty()
< {
    _id: ObjectId('693b1d90fe658639825f69a0'),
    player_mongo_id: '69386d6751fff9a4a9475a6f',
    tournament_mongo_id: '693b1d2dc25b262634a0b04d',
    GameRound: 'Semi-Finals',
    GameRank: 30,
    Oponent: 'Marin Cilic',
    WL: 'W',
    Score: '64 62'
  }
```

Figura 10. Integridade de um registo da tabela "Player_Per_Game"

i. TRATAMENTO DOS ATRIBUTO "OPONENT", "GROUND" E "PLAYERNAME"

Numa primeira fase, foram removidos todos os registos em que o oponente surgia identificado como "*bye*", uma vez que estes correspondem a jogos que não chegaram efetivamente a realizar-se (avanço automático na ronda, devido a desistência ou número ímpar de jogadores).

```
>_MONGOSH
> db.Player_Per_Game.find({Oponent:"bye"},{}).count()
< 19239
```

Figura 11. Contagem dos registos onde o {Oponent:"bye"}

Após a eliminação destes registos da coleção *"Player_Per_Game"*, ficamos com um total de 1 289 596 registos.

Concluímos também que existem 7 registos onde o "*Oponent"* continha o valor " ". Através de diversas fontes foi possível apurar 3 oponentes, pelo que 3 registos foram atualizados para o nome do respetivo oponente e 4 deles foram atualizados para o valor "*Unknown*".

Em seguida, procedeu-se à limpeza de registos com datas inválidas, garantindo que apenas jogos com informação temporal correta permanecessem na coleção. Foram também eliminados registos duplicados, de forma a assegurar que cada jogo fosse representado uma única vez na base de dados.

Foram ainda identificadas situações em que determinados encontros não apresentavam informação relativa ao oponente. Procedeu-se então à pesquisa e correção manual desses casos, completando os sete registos em falta. De forma complementar, realizou-se uma normalização global do tipo de piso *"Ground"*, aplicando o mesmo procedimento utilizado na coleção "*Tournaments"* e assegurando que todos os jogos encontrados, apresentassem pisos válidos e uniformizados.

Verificou-se que existiam 191 registos com o campo *"Ground"* vazio. Foi possível realizar a imputação em três torneios distintos (M15 Opava, M15 Antalya, M15 Cancun), porém existem ainda 10 registos onde não foi possível fazer a imputação pelo que, decidiu-se manter estes registos iguais. No total foram normalizados 188 registos.

Os registos sem tipo de chão foram mantidos pois representavam (0,000137 %) dos torneios totais algo pouco significativo, foi apenas trocado o valor do campo *"Ground"* para*"Unknown"*. Não existe nenhuma fonte legítima que confirme o tipo de piso nestes torneios.

Por fim, foi efetuada uma nova pesquisa dirigida aos nomes dos oponentes, uma vez que alguns apresentavam o mesmo carácter especial inválido (" ") previamente detetado

na coleção "*Players*". Nesses casos, os nomes foram devidamente corrigidos para garantir uma codificação consistente em toda a base de dados.

ii. NORMALIZAÇÃO DO ATRIBUTO "*SCORE*"

No que respeita ao desempenho desportivo, foi efetuada uma limpeza e normalização do atributo "*Score*". Para tal, foi criado um novo atributo, designado "*ScoreClean*", no qual foram removidos espaços, vírgulas desnecessárias e outras inconsistências de formatação. A partir desta sublista limpa, os resultados foram transformados num atributo designado *"ScoreSets"* (*array)* contendo as diferentes combinações de valores por *set*. A coluna original "*Score*" foi mantida na coleção apenas para efeitos de comparação e validação da consistência dos resultados, no entanto, não foi importada para o *MySQL*, por não ser necessária para o modelo relacional final.

```
  Score : "63 62 67,  75"
▾ ScoreSets : Array (4)
    0: "63"
    1: "62"
    2: "67"
    3: "75"
```

```
  Score : "67,  67,  61 60 40 (RET)"
▾ ScoreSets : Array (6)
    0: "67"
    1: "67"
    2: "61"
    3: "60"
    4: "40"
    5: "(RET)"
```

Figura 12. Scores uniformizados no atributo "ScoreSets"

Foram encontrados 21 *missing values*, isto é, {WL:""}. Como representa uma porção bastante pequena da coleção "*Player_Per_Game*" (cerca de 0,0000163 %) optou-se por deixar estes registos iguais.

Por fim, foi criado o atributo "*WL_Bool*", representando o desfecho de cada jogo para o jogador em causa. Este atributo assume a forma de uma variável auxiliar booleana, onde foi atribuído o valor 1 em caso de vitória ("*W"*) e 0 em caso de derrota ("*L"*) ou *null*.

iii. NORMALIZAÇÃO DOS PAÍSES NA COLEÇÃO "COUNTRYCODES"

Um dos pontos chave do presente projeto, incidiu na normalização dos países, em particular sobre os atributos *"Name"* e *"Code"*. Foi importada uma lista de países com 249 países iniciais, cujo um nome se encontrava mal escrito, procedendo-se à respetiva correção ("Viet Nam" passou para "Vietnam").

Adicionalmente, foram incluídos os países: Kosovo, Czechoslovakia, Yugoslavia, Taiwan e *Unknown*, na base de dados "*CountryCodes*", garantindo a sua representação consistente (com os seus respetivos "*Codes*"). [7]

Recorreu-se a operações de "*updateMany"* sobre a coleção "*WorldCities"*, adicionando o atributo "*Code"* correto e o nome normalizado de acordo com a base de dados "*CountryCodes*". Como consequência, foi possível atribuir o código do país e o nome do país à coleção "*Tournaments*", criando ainda índices específicos sobre estes atributos: um índice sobre o *"Name"* e outro sobre o *"Code"*, de modo a otimizar consultas e junções futuras.

iv. TRATAMENTO DO ATRIBUTO "GAMERANK"

Este atributo continha 98 079 *missing values* onde *{GameRank:"-"}*. Como não será utilizado posteriormente este campo para cálculos numéricos, optou-se por substituir o valor anteriormente mencionado por *"Unknown"*.

Para os 6 registos restantes foi utilizado novamente o comando *"updateMany"* para o valor {*Oponent:"Unknown"}*.

[7] É importante reforçar que todos os países descritos nas situações previamente mencionadas, têm essas informações disponíveis publicamente.

9. IMPORTAÇÃO DOS FICHEIROS E CRIAÇÃO DAS TABELAS EM MYSQL

A construção da base de dados iniciou-se com o desenvolvimento de um modelo relacional capaz de representar, de forma rigorosa e normalizada, a informação histórica fornecida pela ATP relativamente a jogadores, torneios e partidas disputadas ao longo de várias décadas. Para assegurar uma estrutura coerente e facilmente extensível, foram definidas três tabelas principais: *"Players", "Tournaments"* e "*Player_Per_Game"*. Para garantir consistência na representação das naturalidades dos jogadores e países de realização dos torneios, foi ainda incorporada no modelo uma tabela auxiliar designada *"Countries"*.

Todo este processo de estruturação foi apoiado por um mecanismo de importação totalmente automatizado, desenvolvido em *Python*, que assumiu um papel fundamental na passagem dos dados brutos para a base de dados relacional. O script foi responsável por ler os ficheiros finais do *MongoDB*, e criar automaticamente todas as tabelas no servidor *MySQL*, aplicando as restrições e índices definidos no modelo relacional.

Para além disso, o script efetuou a inserção otimizada de todos os registos, garantindo eficiência, reprodutibilidade e minimização de erros manuais. Desta forma, todo o processo de construção da base de dados, desde a importação dos ficheiros até à criação das tabelas e mapeamento dos dados, foi executado de forma sistemática e rigorosa, proporcionando uma base sólida para a fase analítica que se seguiu.

10. CRIAÇÃO DO MODELO RELACIONAL

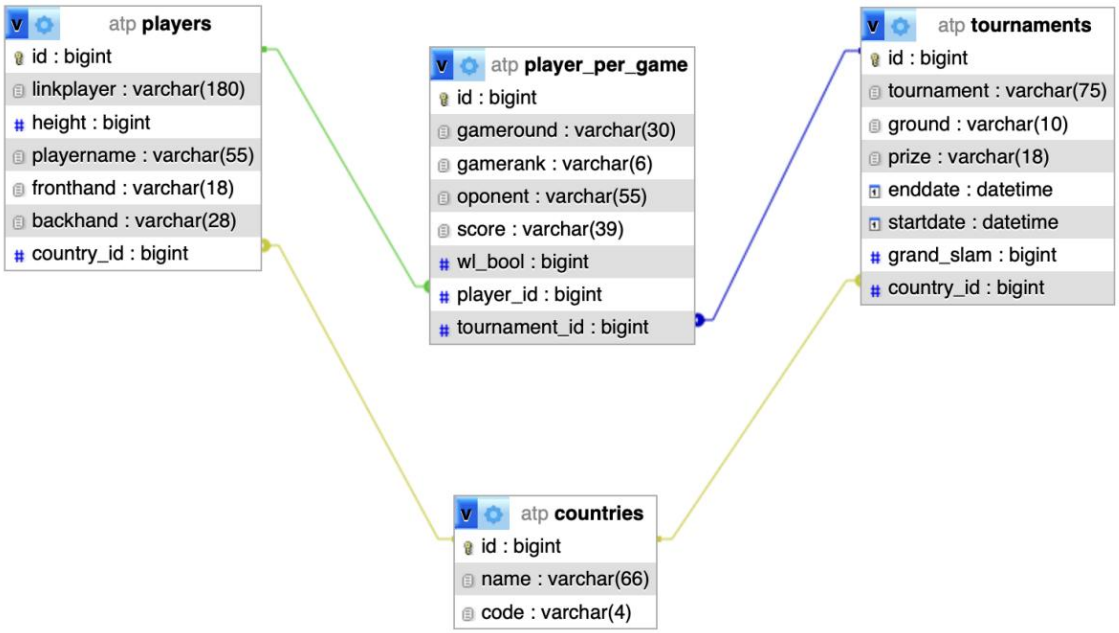

Figura 13. Modelo Relacional da ATP

A construção de um modelo relacional robusto representado na Figura 13. Modelo Relacional da ATP foi um passo fundamental para garantir a integridade, consistência e eficiência no armazenamento e análise de dados. No âmbito deste trabalho, foi desenvolvido um esquema relacional destinado a representar informação histórica e estatística sobre jogadores de ténis, torneios e partidas individuais disputadas ao longo de várias décadas. O modelo foi concebido de forma a assegurar a normalização dos dados, evitar redundâncias e permitir análises agregadas de elevada complexidade.

O modelo é composto por três entidades principais: "*atp players", "atp tournaments" e "atp player_per_game"* e uma entidade auxiliar: *"atp countries"*. Cada uma destas tabelas desempenha um papel distinto no ecossistema informacional, contribuindo para a representação coerente das relações entre jogadores, competições e encontros.

A tabela "*atp players"* armazena informação individual de cada atleta, constituindo a entidade base do modelo. Contém atributos como o nome, o link do player, a naturalidade nacionalidade, ano de nascimento e identificadores internos, sendo que cada registo representa um jogador único. Esta tabela foi concebida para garantir a unicidade dos atletas, funcionando como repositório central para atributos descritivos não repetíveis.

A tabela "*atp tournaments*" descreve todos os torneios presentes. Para cada torneio são armazenados atributos como o nome oficial, cidade, país, piso de jogo, prémio

monetário e datas de início e fim. A existência desta entidade permite separar claramente a caracterização de um torneio da informação relativa aos jogos nele realizados, assegurando normalização e fácil atualização dos metadados associados às competições.

A tabela "*atp player_per_game"* constitui a entidade central da análise competitiva, representando cada jogador em cada jogo disputado. Ou seja, um único encontro é representado por dois registos: um para o vencedor e outro para o vencido. Esta tabela contém atributos como o identificador do jogador, o identificador do torneio, a ronda disputada, o resultado (incluindo conjuntos e pontuações parciais) e indicadores de vitória/derrota.

Para além das três entidades principais (Players, Tournaments e Player_Per_Game), o modelo relacional foi expandido com a inclusão de uma tabela auxiliar designada "*atp countries*". Esta tabela desempenha um papel fundamental na normalização dos atributos relacionados com países de nascimento, códigos nacionais e países de realização dos torneios, reforçando a consistência semântica e a integridade dos dados ao longo de toda a base de dados.

11. CRIAÇÃO DE CHAVES PRIMÁRIAS E ESTRANGEIRAS

No âmbito da definição das estruturas internas do modelo, a utilização adequada de chaves primárias e secundárias revelou-se essencial para garantir a integridade referencial e a correta articulação entre as diferentes entidades. Em todas as tabelas do esquema relacional foi definido um atributo id como chave primária, responsável por identificar de forma unívoca cada registo e por permitir operações de consulta, atualização e eliminação sem ambiguidade. Esta opção assegura não só a consistência interna das entidades, como também a estabilidade dos relacionamentos estabelecidos entre elas.

As chaves secundárias (estrangeiras), desempenham um papel central na representação das dependências existentes entre jogadores, torneios e partidas. Na tabela "*Players"*, o atributo "*country_id"* estabelece a ligação direta ao país de origem do atleta, referenciando a tabela *Countries* e permitindo, assim, a uniformização da informação geográfica sem redundância. Já na tabela "*Player_Per_Game",* os atributos "*player_id"* e "*tournament_id"* funcionam como chaves secundárias, assegurando que cada registo de desempenho está corretamente associado ao jogador e ao torneio a que diz respeito. Este mecanismo assegura que nenhuma partida possa existir sem estar devidamente associada a um atleta e a uma competição válida. De modo semelhante, na tabela "*Tournaments"*,

o campo "*country_id*" reforça a coerência entre os eventos e a sua localização, evitando inconsistências e promovendo a reutilização da informação sobre países.

A articulação destas chaves permite, assim, a construção de um modelo com integridade relacional robusta, no qual cada entidade se encontra corretamente contextualizada e ligada às restantes. Para além de garantir a fiabilidade dos dados armazenados, esta estrutura facilita a realização de análises complexas, a geração eficiente de consultas e a expansão futura do sistema sem comprometer a sua coerência interna.

12. CONCLUSÃO

O trabalho realizado evidencia a importância de um processo rigoroso de preparação, integração e modelação de dados, sobretudo quando se trabalha com fontes amplas e historicamente complexas, como as provenientes da ATP Tour. A aplicação de técnicas de limpeza e transformação de dados permitiu assegurar a coerência e a fiabilidade da informação ao longo de todas as etapas do projeto.

A estrutura resultante não só organizou os dados de forma eficiente, como também estabeleceu uma base sólida para análises futuras. Esta abordagem possibilitou a exploração de padrões de desempenho, da evolução histórica dos jogadores e das relações competitivas no ténis profissional masculino, contribuindo para uma compreensão mais aprofundada da modalidade.

13. WEBGRAFIA

[1] Sofascore. (2018). *Alexandru Vasile Manole vs Laurentiu Mandocescu*. Sofascore.com. https://www.sofascore.com/cs/tennis/match/laurentiu-mandocescu-alexandru-vasile-manole/IxRsiGRb

[2] dos, C. (2015, October 10). *tenista peruano*. Wikipedia.org; Wikimedia Foundation, Inc. https://pt.wikipedia.org/wiki/Carlos_di_Laura

[3] Wikipedia Contributors. (2025, October 2). *1983 Davis Cup Americas Zone*. Wikipedia; Wikimedia Foundation.

[4] eHM, s.r.o. (2018). *Felipe Derdoy vs. Vicente Manuel Rivas Maturana 12.11.2018 - Chile F1 (Vina del Mar) | TenisRezultati.com.* Tenisrezultati.com. https://www.tenisrezultati.com/atp/mec/felipe-derdoy-VS-vicente-manuel-rivas-maturana/chile-f1-vina-del-mar-2018

[5] Sofascore. (2018). *Michael Redlicki vs Lucas Gomez.* Sofascore.com. https://www.sofascore.com/cs/tennis/match/lucas-gomez-michael-redlicki/nzysJvz

[6] Wikipedia Contributors. (2025, July 19). *Grant Stafford.* Wikipedia; Wikimedia Foundation.

[7] *Alfredo Perez.* (2024). ATP Tour. https://www.atptour.com/en/players/alfredo-perez/pl39/overview

[8] Wikipedia Contributors. (2025, March 30). *Nathan Healey.* Wikipedia; Wikimedia Foundation.

[9] *Johannes Ingildsen*. (2024). ATP Tour. https://www.atptour.com/en/players/johannes-ingildsen/i411/overview

[10] *James Trotter*. (2024). ATP Tour. https://www.atptour.com/en/players/james-trotter/t0bw/overview

[11] *Sebastian Prechtel.* (2024). ATP Tour. https://www.atptour.com/en/players/sebastian-prechtel/pl38/overview

[12] *Nicolas Niño Mendoza*. (2024). ATP Tour. https://www.atptour.com/en/players/nicolas-ni%C3%B1o-mendoza/n0dg/overview

[13] *Tim Büttner*. (2024). ATP Tour. https://www.atptour.com/en/players/tim-b%C3%BCttner/b0b7/overview

[14] *Vladimír Reznicek*. (2024). ATP Tour. https://www.atptour.com/en/players/vladimr-reznicek/r0dy/overview

[15] *Enrique Ordoñez*. (2024). ATP Tour. https://www.atptour.com/en/players/enrique-ordo%C3%B1ez/o0ch/overview

[16] *Mateo Castañeda*. (2024). ATP Tour. https://www.atptour.com/en/players/mateo-casta%C3%B1eda/c0lg/overview